

비정형 데이터 분석 · 텍스트 기반 ESG 연구

공시 언어로 ESG 등급을 예측할 수 있는가?

DART 사업보고서 텍스트와 KCGS ESG 등급의 수준·변화량 분석

비정형 데이터 분석 1조

하지운 박미정 최사랑 이채민

CONTENTS

목차

- | | | | |
|----|----------------------------|----|-------------------------------|
| 01 | EXECUTIVE SUMMARY
결과 요약 | 05 | SENTIMENT
ESG 감성분석 (수준·변화) |
| 02 | INTRODUCTION
연구 배경과 가설 | 06 | FINDINGS
결과: 수준 vs 변화량 |
| 03 | DATA
데이터: 균형 패널 | 07 | DISCUSSION
결론 |
| 04 | METHOD
코퍼스·사전 구축·상관분석 | 08 | CONCLUSION
연구 가치 및 시사점 |

결과 요약

분석 파이프라인

ESG 서술 추출 → Kiwi+BGE 사전 확장 → KR-FinBERT 감성 → 기업-연도 지표

등급 수준 ↔ 언어

강한 양(+)의 상관
ESG $\rho \approx 0.72$ · 긍정비율 $\rho \approx 0.39$

등급 변화 ↔ 언어 변화

유의한 관계 없음
감성변화 $p > 0.26$ · OLS $R^2 \approx 1\%$

변화그룹 차이

감성 아닌 '분량'에서만 유의
단어 수 $p \approx 0.006$ · ESG문장수
 $p \approx 0.026$
(절대 감성 $p \approx 0.17 \sim 0.50$ 비유의)

핵심 결론

수준에서 보이는 강한 상관은 공시 언어의 효과가 아니라 기업 규모·역량 같은 공통요인의 영향일 수 있으며, 차분(변화량)으로 그 요인을 제거하면 예측력은 사라진다.

연구 배경과 가설

배경

ESG 공시 의무화·공시량 급증
→ '공시 내용과 실제 등급이 정합적인가?'

문제의식

단순 빈도는 분량·반복만으로 점수 ↑ → 그린워싱 구분 불가
→ 단어의 양(TF-IDF) + 문맥의 질(감성 톤) 함께 측정

차별점

정적: 당해 톤 ↔ 당해 등급 (인과 불분명)
동적(본 연구): 전년 톤 변화 → 차년도 등급 변화 (공통요인 통제)

연구 가설 H_0 : 공시 톤의 변화량은 차년도 등급 변화량과 관련이 없다

→ 이 귀무가설의 채택 여부가 본 연구의 결론을 규정한다

데이터: 균형 패널

381

firm-year (균형 패널)

127

상장기업 × 3년(2022–2024)

254

변화량 패널 (전년 lag)


0

ESG 등급 결측

설계

- 등급: KCGS, 순위형 $D < C < B < B+ < A < A+$ ($\rightarrow 0 \sim 5$)
- 시차 설계: t 년 보고서 $\rightarrow t+1$ 년 ESG 등급 매칭
- 변화량 검증: 연속 두 회계연도 관측 기업만 사용

변화량 패널 254건의 등급 변화 구성



■ 유지 144 ■ 상승 57 ■ 하락 53

코퍼스 구축

DART 사업보고서 원문(XML)에서 ESG 서술 집중 3개 섹션만 추출

- II 사업의 내용
- IV 경영진단 및 분석의견
- VI 이사회 등 회사의 기관


정제: 태그 제거 · 유니코드 NFKC 정규화 · URL 치환 · 공백 정리

산출 결과

- 127개 기업 × 3년 = 381 firm-year, 22개 산업
- 모든 행이 3개 섹션 모두 보유, 등급 결측 0
- 문서당 평균 약 14,974단어 (편차 큼)
- 기업·연도 단위로 결합 + 단어 수·문장 수 기록

탐색적 데이터 분석 (EDA)

전체 ESG 등급 분포 (n=381)




관찰 포인트

- A등급 32.3%로 최다, 양극단(D·A+)은 얇음
- 연도별 평균 2.54→2.65→2.61, 중앙값 3 — 안정적
- 산업 라벨 다수 결측 → 참고용만 (연구 한계)
- 문서 길이 편차 큼: 1,829 ~ 71,775 단어
- → 분량이 count 점수 교란 가능 → 분량 통제 + TF-IDF 병행

ESG 사전 구축 & 임베딩 확장

- 문제의식: 수작업 시드=재현율 ↓ / 무분별 확장=정밀도 ↓ → 임베딩 절충
- ① 시드 사전: E·S·G 각 18개 핵심 질의어
- ② 후보: Kiwi 형태소 → 빈도 필터 → 최대 3만 개
- ③ 확장: BGE-m3-ko 코사인 유사도로 가까운 축에 배정
- ④ 점수화: 문서별 count + TF-IDF
- ⑤ 임계값: θ 0.1~1.0 스윙 → 증분설명력(HC3 OLS·부분 F)으로 선택


임계값(θ)별 확장 모형 R^2 — $\theta=0.80$ 최고점



채택 kiwi + BGE $\theta=0.80$ R^2 0.300 → 0.432 (부분 F $p \approx 8.7e-19$)
 최종 사전 E 61 · S 38 · G 53 | fastText($\theta=0.70$) 강건성 검증

상관분석 & 비모수 검정 (등급 수준)

Spearman 순위상관 ρ (count, $n=381$)




세 가지 비모수 검정

- **Spearman: ESG $\rho=0.725$ 등 전부 $p<1e-26$**
 - count $\approx$ TF-IDF, 연도 별로도 유지
- **Mann-Whitney U (A $\uparrow$ vs B+ $\downarrow$): 전 항목 $p<1e-17$**
 - rank-biserial 0.51~0.71 (중간~큰 효과)
- **Kruskal-Wallis (6등급): 전부 유의 (ESG $H\approx 205$)**
 - $\rightarrow$ Dunn 사후검정 유의 쌍 87개 (단조 증가)

단, 이는 '수준'에 대한 연관 — 변화량 예측력과 구별됨

ESG 감성분석 ① — 등급 수준

ESG 문장 감성 분포 (총 21,242개)



■ 중립 84.2% ■ 긍정 11.9% ■ 부정 3.9%

KR-FinBERT · 금융 텍스트 특화 → 사업보고서는 중립 문체 지배


등급 수준과의 관계

- 긍정 비율 $\rho=0.387$ · 평균 감성 $\rho=0.358$ — 유의(+)
- 중립 비율 $\rho=-0.344$ — 유의(-)
- 부정 비율 $\rho=0.024$ ($p=0.64$) → 비유의 (부정 3.9%로 희박)
- OLS(HC3): 평균감성만 $R^2=0.118$ → 분량 통제 시 0.269
 - 긍정비율 유의 / 부정비율 비유의 / 분량이 최강 설명변수
- Kruskal(긍·부정 4분면): $H \approx 41.6$, $p < 1e-8$ — 긍정 ↑ 집단 등급 ↑

핵심: 긍정 서술 ↔ 등급 양(+) 연관 (단, 분량 교란 · 인과 아님)

ESG 감성분석 ② — 등급 변화량

수준 vs 변화량 Spearman ρ



차분으로 공통요인 제거 후

- 질문: ESG 언어가 좋아진 기업이 차년도 등급도 오르는가?
- 감성변화 모두 비유의: net $\Delta p=0.26$ · 긍정 $\Delta p=0.41$ · 부정 $\Delta p=0.58$
- Kruskal: 감성 비유의 / 분량 지표만 유의(분량 $\Delta p=0.006$)
- OLS: 전 모형 $R^2 \approx 1\%$, 감성 계수 전부 비유의
 - 유일 $p < 0.05$ = 분량 변화($p=0.13$) → 내용 아닌 분량, 보정 시 소멸

→ 공시 언어의 변화는 등급 변화를 예측하지 못함

결과 — 변화는 무의미, 수준은 유의

변화 감성 변화량 모두 비유의 (net $\Delta p=0.26$ · 긍정 $\Delta p=0.41$)
 작년보다 돈을 좋게 쓰면 등급이 오르는가?

아니다



변화 단변량 $p=0.039$ 뿐 → 다변량서 소멸, OLS $R^2 \approx 1\%$
 보고서 분량을 늘리면 등급이 오르는가?

아니다



수준 Spearman ESG $p=0.72$ · 긍정비율 $p=0.39$ (모두 $p < 1e-14$)
 ESG를 긍정적으로·비중 있게 쓰는 기업이 등급이 높은가?

그렇다



해석

유의한 결과는 '수준'의 횡단면 연관 — 글을 잘 써서 등급이 오른 게 아니라, 원래 등급이 높은 기업이 평소에도 ESG를 긍정적으로·비중 있게 서술하기 때문(공통요인). 그래서 '변화'로 보면 효과가 사라진다. (오답노트 비유: 평소 잘하는 학생이 오답노트도 잘 쓴다)

부록 — 생존분석 (Cox 비례위험모형)

설계

- 목적: 변화량 분석 보완 — 등급 이행을 '시간 속 사건'으로
- 공변량: 통합 ESG 감성지수(긍정-부정 문장 수)
- 기간 = 기업별 관측 연차 / 사건 = 등급 변동 발생
- **Cox PH 선택: 중도절단 포함, 분포 가정 불필요(준모수)**

결과

유의한 신호 없음

Concordance ≈ 0.59 — 뚜렷한 방향성·설명력 부재

- → 변화량 분석과 일관된 결론
- 한계: 표본·사건 수 제한, 등급 이행의 단일사건 단순화
- 공시 언어가 등급 이행을 설명한다는 신호는 부록에서도 확인 안 됨

CONCLUSION

귀무가설 기각 실패 — 톤·분량 조작으로는 등급을 올린다는 증거를 찾지 못했다

연구의 가치 "공시 텍스트의 단기적 톤 변화를 실제 성과 변화 지표로 선불리 해석해서는 안 된다"

보고서가 긍정적으로 바뀌었다는 사실을 ESG 성과 개선의 증거로 받아들이면 안 됨 — 실증적 경고

한계점

■ 수준의 강한 연관은 공통요인 효과일 가능성 (미통제)

■ FinBERT가 상투적 표현을 과대긍정했을 여지

■ 3년 파일럿 패널 · 업종 라벨 약 78% 결측

■ 부정 문장 3.9%로 데이터 쓸림 → 변화 신호 약화

■ 공시 문장 ≠ 실제 ESG 성과 직접 측정치

■ 생존분석: 3년 시계열·부정문장 회소 → 보조 검토 한정

연구의 가치 · 시사점

핵심 가치

"공시 텍스트의 단기적 톤 변화를 실제 기업 성과 변화 지표로 선불리 판단해서는 안 된다"

감성 점수가 등급을 잘 설명하느냐가 아니라, 톤 변화를 성과 신호로 오독하는 것을 경고하는 데 의의

정책적 시사점

- 공시 톤이 등급 수준과 연동된다는 사실 확인
- 공시는 본래 중립·객관적이어야 함
- → 향후 공시의 객관성·중립성 논의에 참고점이 될 수 있음

향후 연구 방향

- 표본 규모·시계열 확대 → 변화·생존분석 정교화
- 업종별 특성 통제 (가중치 부여)
- 예: 철강 제조업 vs IT 플랫폼 — 환경 리스크 출발선이 다름